
Trabalho de Desenvolvimento - GA - APP em MATLAB

Eduardo Junqueira nº1251561, 1251561@isep.ipp.pt,
João Azevedo nº 1251566, 1251566@isep.ipp.pt,
Rodrigo Martins nº 1250398, 1250398@isep.ipp.pt.
Repositório GitHub: [1].
Supervisionado por Filipe Azevedo, fta@isep.ipp.pt.

Mestrado em Engenharia Electrotécnica e de Computadores
Área de Especialização em Automação e Sistemas



DEPARTAMENTO DE ENGENHARIA ELETROTÉCNICA
Instituto Superior de Engenharia do Porto

Dezembro, 2025

Índice

Lista de Acrónimos	3
Lista de Figuras	4
1 Introdução	2
1.1 Contextualização	2
1.1.1 Objetivo	2
1.1.2 Resultados esperados	3
1.2 Organização do relatório	3
2 Desenvolvimento	4
2.1 Problema Exercício (Ex):2	4
2.2 A ter em consideração sobre o Ex 2	5
2.2.1 Resolução com Genetic Algorithms (GA) Toolbox	6
2.2.2 Resolução GA com a implementação de Seleção por Roleta	7
Métodos de Seleção dos Pais — Roleta	7
Evolução do GA e Resultados Gráficos	9
2.2.3 Resolução GA com a implementação de Seleção por Torneio	9
2.2.4 Resolução alínea a) Manualmente:	11
3 Aplicação (APP) em MATrix LABoratory (MATLAB)	14
3.1 Menu Principal	15
3.2 Ex 1	16
3.3 Ex 2	17
3.3.1 Seleção do Método de Escolha	18
3.3.2 Definição dos Parâmetros Variáveis	18
3.3.3 Execução com a Toolbox do MATLAB	19
3.3.4 Execução do Algoritmo Genético Implementado	20
3.3.5 Comparação dos Resultados	22
3.3.6 Tratamento de Erros e Robustez da Aplicação	23
3.3.7 Resultados Obtidos	25
4 Conclusão	26
Referências	27

Lista de Acrónimos

APP	Aplicação
Ex	Exercício
Fig	Figura
GA	Genetic Algorithms
MATLAB	MATrix LABoratory
Uc	Unidade Curricular

Lista de Figuras

2.1	Diagrama de Rede Ex 2 [5]	5
3.1	Figura (Fig) que representa o Menu Inicial da APP	15
3.2	Fig que representa a APP do Ex 1 em MATLAB APP.	16
3.3	Fig que representa a APP do Ex 2 em MATLAB APP	17
3.4	Exemplo de alerta exibido quando Pmax é inválido	19
3.5	Visualização da execução do AG através da GA Toolbox	20
3.6	Mensagem apresentada na APP com os resultados numéricos da Toolbox obtidos	20
3.7	Resultados obtidos com o GA desenvolvido: (a) Evolução do custo mínimo, (b) Curva do Custo Total, com ponto ótimo assinalado, (c) Distribuição da população Final, P_{G1} .	21
3.8	Mensagem apresentada na APP com os resultados numéricos do Algoritmo Genético obtidos	21
3.9	Mensagem apresentada pelo botão de Comparação na APP	22
3.10	Comparação da evolução do custo mínimo entre os métodos de seleção	22
3.11	Comparação da distribuição da população entre os métodos de seleção	23
3.12	Exemplo de alerta exibido quando não é possível fazer a comparação	24

Resumo

Ex nº2 resolvido durante as aulas laboratoriais da Unidade Curricular (Uc) de GA , tem como objetivo neste relatório ser feito em uma APP com o uso da ferramenta MATLAB e todas as suas funcionalidades de design e script de código com o uso da Toolbox de Otimização.

Assim, a explicação de **métodos de seleção** tais como:**I:**fitness,**II:**roda da roleta,**III:**torneio e **IV:**elitista.

Aplicação também de **métodos de alteração** dos indivíduos tais como: **I:** "crossover"e **II:** "mutação".

Estes métodos são importantes a considerar através de Fig neste Ex realizado e em testes feitos.

Toda a informação respetiva aos exercícios deste relatório encontra-se no repositório [1].

Capítulo 1

Introdução

O MATLAB é um software poderoso como por exemplo para álgebra linear, matemática computacional e GA que é o objetivo desta Uc. Ele também permite automatização de tarefas ou escrever funções/scripts em sua própria linguagem **.m**.

O criador do MATLAB foi "Cleve Moler" é um matemático e cientista da ciência da computação [2]. O criador de GA foi "John Henry Holland", foi cientista e professor, pioneiro em sistemas complexos e ciência não-linear. [3]

1.1 Contextualização

O GA, por outra perspectiva é implementado dentro do MATLAB. Este é um algoritmo que pretende seguir a base da ciência e da computação para encontrar a melhor solução possível em resolução a um problema [4].

Uma "optimization toolbox" no MATLAB é um pacote de funções, scripts e arquivos de apoio, desenhados para expandir as capacidades do MATLAB em áreas específicas, como inteligência artificial em particular GA.

1.1.1 Objetivo

O objetivo deste trabalho de desenvolvimento consiste na realização do Ex nº2, que está no enunciado de exercícios fornecido pelo professor [5], onde será realizada uma APP no MATLAB que permita resolver o mesmo recorrendo há Toolbox de Otimização e sem a toolbox de Otimização comparando e explicando num relatório que visa explicar todo o trabalho de desenvolvimento.

1.1.2 Resultados esperados

Os resultados esperados pretendem ser os mais sucintos possíveis e que mais se ajustem aos parâmetros esperados pelo enunciado do Ex [5].

1.2 Organização do relatório

A sua estrutura do relatório é organizada da seguinte forma:

- No Capítulo 2 descreve-se o Ex e seu código explicado com o enunciado do mesmo!
- No Capítulo 3 é apresentado os resultados obtidos da APP e sua respetiva explicação!
- No Capítulo 4 são apresentadas as conclusões finais.

Capítulo 2

Desenvolvimento

2.1 Problema Ex:2

Foi proposto pelo professor Filipe Azevedo da Ufpe de GA desenvolver uma APP, em MATLAB recorrendo ao uso da ferramenta "Design APP", para resolver o Ex 2 cuja a pergunta do mesmo encontra-se em baixo [5]. A resolução deste exercício encontrasse no repositório do GitHub [1].

Considere a rede da Fig 2.1. Admitindo que a função custo de produção de cada um dos geradores são dadas pelas Equações 2.1 e 2.2:

$$C_1(P_{G1}) = 0,3 \cdot P_{G1} + 0,01 \cdot P_{G1}^2 - \quad (2.1)$$

$$C_2(P_{G2}) = 0,2 \cdot P_{G2} + 0,3 \cdot P_{G2}^2 \text{ (€/h)} \quad (2.2)$$

a) Determine, recorrendo à Toolbox de Otimização do MATLAB, o despacho económico sem perdas da rede da Fig 2.1 e compare os resultados com os obtidos recorrendo aos multiplicadores de Lagrange.

b) Determine o despacho, tal como determinou no exercício anterior, admitindo que a potência máxima do Gerador 1 da Fig 2.1 é igual a 0,5 p.u.

c) Desenvolva um GA em MATLAB que permita resolver os exercícios anteriores. Compare os resultados obtidos com os da Toolbox de Otimização do MATLAB.




Figura 2.1: Diagrama de Rede Ex 2 [5]

2.2 A ter em consideração sobre o Ex 2

O exercício 2 consiste em determinar o **despacho económico sem perdas** de uma rede elétrica com dois geradores, como representado na Fig 2.1. As funções de custo de produção dos geradores são dadas pelas Equações 2.1 e 2.2. A potência total da rede é limitada a 0,9 p.u. ,sendo que, numa das alíneas, a potência máxima do Gerador 1 é fixada a 0,5 p.u. Sendo esta a alínea **b**).

O objetivo do exercício é determinar a **distribuição de potência entre os dois geradores** que minimize o custo total de operação da rede, recorrendo a diferentes métodos:

I: Toolbox de Otimização do MATLAB: utilizando funções de otimização convencionais com a ferramenta Toolbox Optimization para calcular o despacho económico sem perdas.

II: GA desenvolvido manualmente: neste caso usamos duas estratégias de seleção:

- Seleção por **roleta**;
- Seleção por **torneio**.

Na **APP desenvolvida**, foi possível integrar todas as alíneas em um único ambiente gráfico, permitindo ao utilizador:

- Escolher se quer visualizar os **gráficos da Toolbox** ou do **GA**.
- Selecionar o **método de seleção** dentro do GA (roleta ou torneio).
- Ajustar os **parâmetros do GA**, incluindo:
 - Potência máxima do Gerador 1 ($P_{\max}$);
 - Tamanho da população (N_{pop});
 - Número de gerações (N_{ger});
 - Probabilidade de crossover (P_c);
 - Probabilidade de mutação (P_m).
- Comparar os resultados do GA com os obtidos pela **Toolbox** através de um botão de comparação.

A implementação referida anteriormente, permite não só verificar o funcionamento dos métodos de otimização, mas também analisar a influência dos parâmetros do GA na convergência e na qualidade da melhor solução obtida para a solução ótima.

2.2.1 Resolução com GA Toolbox

Para resolver o despacho económico da 2.1, utilizou-se a GA Toolbox do MATLAB. A **Função Objetivo**: é definida como o custo total da geração de energia, dado por

$$C_{\text{total}}(P_{G1}) = C_1(P_{G1}) + C_2(P_D - P_{G1}), \quad (2.3)$$

onde $P_D = 0.9$ p.u. é a potência total exigida, P_{G1} representa a potência gerada pelo Gerador 1, e $P_{G2} = P_D - P_{G1}$ a potência gerada pelo Gerador 2. Os limites de operação do Gerador 1 são definidos por $P_{\min}$ e $P_{\max}$, passados como argumentos para o GA. C_1 e C_2 representam as Equações 2.1 e 2.2.

O GA do MATLAB é configurado com funções de "plotagem" integradas (`PlotFcns`) para acompanhar a convergência, incluindo a evolução do melhor indivíduo, do melhor valor de custo em cada geração e da expectativa de *fitness* da população:

```

1 options = optimoptions('ga', ...
2     'PlotFcns', {@gaplotbestf, @gaplotbestindiv,
3     @gaplotexpectation, @gaplotstopping});
4 [x, fval] = ga(C_total, 1, [], [], [], [], Pmin, Pmax, [], options
5 );
6 PG1_tool = x;
7 PG2_tool = PD - x;
8 custo_min_tool = fval;
```

O GA retorna o ponto ótimo correspondente ao Gerador 1, P_{G1}^{tool} , conseguindo então calcular a potência correspondente ao Gerador 2, P_{G2}^{tool} , e o custo mínimo $C_{\min}^{\text{tool}}$.

Para além dos gráficos configurados na função GA do MATLAB, também foi gerado um gráfico para a análise visual:

- **Curva do custo total:** mostra C_{total} em função de P_{G1} , com o ponto ótimo identificado;
- **Ponto ótimo:** destacado no gráfico com um marcador verde, permitindo fácil identificação do despacho económico;
- **Comparação:** visual com o GA desenvolvido manualmente.

Desta forma, a Toolbox permite obter rapidamente o despacho económico sem perdas da rede, servindo de referência para comparação com os métodos desenvolvidos manualmente.

2.2.2 Resolução GA com a implementação de Seleção por Roleta

Outra forma de resolver o despacho económico da rede, é desenvolvendo um código utilizando as funções de custo definidas pelas Equações 2.1 e 2.2, garantindo o balanço de potência descrito pela Equação 2.3. A variável de decisão é P_{G1} , estando limitada ao intervalo permitido para o gerador, $P_{\min}$ e $P_{\max}$.

A população inicial é gerada aleatoriamente dentro dos limites do Gerador 1, sendo depois avaliado cada indivíduo através do custo total do sistema, equação 2.3. De forma a garantir que as soluções com menor custo sejam priorizadas durante o processo, usou-se o inverso do custo como função fitness:

$$\text{fitness}(i) = \frac{1}{C(i) + 10^{-6}} \quad (2.4)$$

onde 10^{-6} é adicionado para evitar divisão por zero.

A seleção dos indivíduos para reprodução (pais) é realizada pelo método da seleção de roleta, em que a probabilidade de escolha é proporcional à função *fitness*. Após esta seleção, são aplicados os operadores genéticos de **crossover e mutação** para gerar novos indivíduos (filhos). Para além disso, utiliza-se também a seleção de elitismo, assegurando que o melhor indivíduo de cada geração seja preservado.

A evolução do **custo mínimo** ao longo das gerações é representada graficamente, assim como a distribuição final da população e a localização da solução ótima (menor custo) sobre a curva do custo total.

Métodos de Seleção dos Pais — Roleta

*

O método de seleção por roleta consiste na escolha de indivíduos com probabilidade proporcional ao seu *fitness*, fazendo com que os indivíduos com menor custo

tenham maior probabilidade de gerar filhos. O processo é implementado em três etapas:

1. **Normalização dos valores de *fitness*** para formar uma distribuição de probabilidade:

```
1 total_fit = sum(fitness)
2 prob = fitness / total_fit);
```

2. **Cálculo da soma acumulada das probabilidades**, que representa a roleta virtual:

```
1 prob_acum = cumsum(prob);
```

3. **Método de seleção por sorteio aleatório** para selecionar os indivíduos que serão pais na próxima geração:

```
1 for i = 1:N
2     r = rand;
3     idx = find(prob_acum >= r, 1, 'first');
4     pais(i) = pop(idx);
5 end
```

Estes métodos mantêm variabilidade genética na população, mas não garante que os melhores indivíduos sejam sempre selecionados, o que pode resultar em convergência mais lenta em alguns casos.

Métodos de Alteração: Crossover, Mutação e Elitismo

Após o processo de seleção dos pais, os indivíduos passam por mecanismos de reprodução que permitem explorar novas soluções (filhos) dentro das soluções já calculadas (pais).

- **Crossover** — Com probabilidade P_c , dois pais são combinados através de uma troca aleatória entre os seus valores, gerando dois filhos:

```
1 for i = 1:2:N-1
2     if rand < Pc
3         alfa = rand;
4         filhos(i) = alfa*pais(i) + (1-alfa)*pais(i+1);
5         filhos(i+1) = alfa*pais(i+1) + (1-alfa)*pais(i);
6     end
7 end
8 filhos = max(min(filhos, Pmax), Pmin);
```

- **Mutação** — Com probabilidade P_m , um gene é substituído por um novo valor aleatório dentro dos limites estipulados:

```

1 for i = 1:N
2     if rand < Pm
3         filhos(i) = Pmin + (Pmax - Pmin)*rand;
4     end
5 end

```

- **Elitismo** — Para evitar perda de boas soluções, o melhor indivíduo da geração anterior substitui o pior da nova população:

```

1 [~, idx_worst] = max(C_total(filhos));
2 filhos(idx_worst) = pop(idx_best);

```

Estes métodos garantem o equilíbrio entre a introdução de diversidade e preservação das boas soluções, fazendo com que exista uma convergência progressiva para o despacho de menor custo.

Evolução do GA e Resultados Gráficos

Após a inicialização da população e a avaliação de cada indivíduo, o algoritmo executa o processo evolutivo durante N_{ger} gerações. Em cada iteração, são registrados:

- O melhor custo obtido até ao momento;
- O respetivo valor de P_{G1} associado ao melhor custo.

No final, são gerados gráficos que permitem avaliar a convergência do método:

- **Evolução do custo mínimo:** representação da diminuição progressiva do custo ao longo das gerações;
- **Curva do custo total:** identificação do ponto ótimo encontrado pelo algoritmo;
- **Distribuição final da população:** análise da concentração dos indivíduos, de forma a visualizar a convergência para a solução ótima.

2.2.3 Resolução GA com a implementação de Seleção por Torneio

Tal como no caso anterior, com a seleção roleta (Secção 2.2.2), pretende-se otimizar a variável de decisão P_{G1} de forma a minimizar o custo total do sistema definido pelas Equações 2.1, 2.2 e 2.3. A população inicial é gerada aleatoriamente dentro dos limites do gerador.

Neste caso, a avaliação dos indivíduos é realizada diretamente através do custo total calculado. Ou seja, o custo é utilizado como função *fitness*, sem inversão, ao contrário da seleção de roleta. Isto é possível, porque a estratégia de seleção por torneio escolhe **especificamente o indivíduo com menor custo** dentro de um grupo aleatoriamente sorteado. Assim evitando a necessidade de manipular a função *fitness*.

Seleção dos Pais — Método do Torneio

A seleção por torneio baseia-se em competições locais entre indivíduos da população. Para cada par de pais a selecionar, são escolhidos quatro indivíduos aleatoriamente, realizando-se dois torneios independentes, em que o vencedor de cada torneio apresenta o menor custo (pais):

```
1 for i = 1:2:N
2     idx = randperm(N,4); % 4 indivíduos -> 2 torneios
3     % Torneio 1
4     if custos(idx(1)) < custos(idx(2))
5         pai1 = pop(idx(1));
6     else
7         pai1 = pop(idx(2));
8     end
9     % Torneio 2
10    if custos(idx(3)) < custos(idx(4))
11        pai2 = pop(idx(3));
12    else
13        pai2 = pop(idx(4));
14    end
15    pais(i) = pai1;
16    if i+1 <= N
17        pais(i+1) = pai2;
18    end
19 end
```

Este método aumenta uma pressão seletiva, acelerando a convergência, pois os melhores indivíduos têm uma probabilidade muito maior de passar à reprodução.

Contudo, se a pressão seletiva for demasiado elevada, a diversidade genética reduz-se rapidamente, podendo resultar numa convergência prematura para soluções não tão ótimas.

Reprodução e Elitismo

O processo de reprodução no método de seleção por torneio utiliza exatamente os mesmos operadores genéticos aplicados no método da roleta (Secção 2.2.2), ou seja, crossover e mutação com probabilidades P_c e P_m , respetivamente, bem como o uso de elitismo para preservar o melhor indivíduo de cada geração. Dessa forma, garante-se

uma comparação justa entre as duas metodologias, uma vez que a única diferença relevante está no mecanismo de seleção dos pais.

Evolução e Resultados Gráficos

O algoritmo executa o processo evolutivo durante N_{ger} gerações, registando-se o melhor custo em cada iteração. Os mesmos tipos de gráficos são gerados para análise comparativa (Secção 2.2.2).

2.2.4 Resolução alínea a) Manualmente:

Esta resolução foi realizada há mão, ou seja, manualmente e explicada aqui neste relatório onde depois obtemos os mesmos resultados comparando com os resultados obtidos na Toolbox de Otimização.

O método dos multiplicadores de Lagrange é uma técnica de otimização utilizada para determinar máximos e mínimos de funções [6]. Para determinar o mínimo ou o máximo de uma função $f(x_1, x_2, \dots, x_n)$, com uma ou mais restrições de igualdade, este método permite transformar o problema restrito num problema sem restrições, através da introdução de variáveis adicionais chamada multiplicador de Lagrange (λ).

$$L(x_1, x_2, \dots, x_n, \lambda) = f(x_1, x_2, \dots, x_n) + \lambda(x_1, x_2, \dots, x_n) \quad (2.5)$$

Os multiplicadores de Lagrange utilizam as derivadas parciais para descobrir o máximo e mínimo da função [6]. As derivadas parciais são dadas pelas seguintes equações:

$$\frac{\partial L}{\partial x_1} = 0 \quad (2.6)$$

$$\frac{\partial L}{\partial x_2} = 0 \quad (2.7)$$

$$\frac{\partial L}{\partial x_n} = 0 \quad (2.8)$$

$$\frac{\partial L}{\partial x_\lambda} = 0 \quad (2.9)$$

Com esta introdução aos multiplicadores de Lagrange, aplicamos à alínea a) do problema. As equações 2.1 e 2.2 são o custo total de cada gerador. Sabendo que a carga total é $P_{G1} + P_{G2} = 0,9 \text{ p.u.}$, ou seja, é preciso minimizar o custo total. Para minimizar, alteramos a expressão e igualamos a 0: $0,9 - P_{G1} - P_{G2} = 0$.

Agora, a equação 2.5 alteramos com as condições do exercício:

$$L(P_{G1}, P_{G2}, \lambda) = C_1(P_{G1}) + C_2(P_{G2}) + \lambda(0,9 - P_{G1} - P_{G2}) \quad (2.10)$$

As derivadas parciais da alínea a):

$$\frac{\partial L}{\partial P_{G1}} = 0 \quad (2.11)$$

$$\frac{\partial L}{\partial P_{G2}} = 0 \quad (2.12)$$

$$\frac{\partial L}{\partial \lambda} = 0 \quad (2.13)$$

Derivadas Parciais:

Derivar em relação a P_{G1}

$$\frac{d}{dP_{G1}}(0, 3P_{G1}) = 0, 3 \quad (2.14)$$

$$\frac{d}{dP_{G1}}(0, 01P_{G1}^2) = 0, 02P_{G1} \quad (2.15)$$

$$\frac{d}{dP_{G1}}\lambda(0, 9 - P_{G1} - P_{G2}) = -\lambda \quad (2.16)$$

$$\frac{\partial L}{\partial P_{G1}} = 0 \Leftrightarrow 0, 3 + 0, 02P_{G1} - \lambda = 0 \Leftrightarrow \lambda = 0, 3 + 0, 02P_{G1} \quad (2.17)$$

Derivar em relação a P_{G2}

$$\frac{d}{dP_{G2}}(0, 2P_{G2}) = 0, 2 \quad (2.18)$$

$$\frac{d}{dP_{G2}}(0, 3P_{G2}^2) = 0, 6P_{G2} \quad (2.19)$$

$$\frac{d}{dP_{G1}}\lambda(0, 9 - P_{G1} - P_{G2}) = -\lambda \quad (2.20)$$

$$\frac{\partial L}{\partial P_{G2}} = 0 \Leftrightarrow 0, 2 + 0, 6P_{G2} - \lambda = 0 \Leftrightarrow \lambda = 0, 2 + 0, 6P_{G2} \quad (2.21)$$

Derivar em relação a λ

$$\frac{d}{d\lambda}(\lambda(0, 9 - P_{G1} - P_{G2})) = 0, 9 - P_{G1} - P_{G2} \quad (2.22)$$

$$\frac{\partial L}{\partial \lambda} = 0 \Leftrightarrow 0, 9 - P_{G1} - P_{G2} = 0 \Leftrightarrow P_{G1} + P_{G2} = 0, 9 \quad (2.23)$$

Igualdade das derivadas

$$\frac{dC_1}{dP_{G1}} = \frac{dC_2}{dP_{G2}} = \lambda \quad (2.24)$$

$$\begin{aligned}
& \begin{cases} 0,3 + 0,02P_{G1} = 0,2 + 0,6P_{G2} \\ P_{G1} + P_{G2} = 0,9 \end{cases} \\
& \Leftrightarrow \\
& \begin{cases} P_{G2} = (0,3 + 0,02P_{G1} - 0,2)/0,6 \\ P_{G1} + P_{G2} = 0,9 \end{cases} \\
& \Leftrightarrow \\
& \begin{cases} P_{G2} = (0,3 + 0,02P_{G1} - 0,2)/0,6 \\ P_{G1} + (0,3 + 0,02P_{G1} - 0,2)/0,6 = 0,9 \end{cases} \\
& \Leftrightarrow \\
& \begin{cases} P_{G2} = (0,3 + 0,02P_{G1} - 0,2)/0,6 \\ 0,6P_{G1} + (0,3 + 0,02P_{G1} - 0,2) = 0,54 \end{cases} \\
& \Leftrightarrow \\
& \begin{cases} P_{G2} = (0,3 + 0,02P_{G1} - 0,2)/0,6 \\ P_{G1} = 0,7097 \end{cases} \\
& \Leftrightarrow \\
& \begin{cases} P_{G2} = (0,3 + 0,02(0,7097) - 0,2)/0,6 \\ P_{G1} = 0,7097 \end{cases} \\
& \Leftrightarrow \\
& \begin{cases} P_{G2} = 0,1903 \\ P_{G1} = 0,7097 \end{cases}
\end{aligned}$$

Agora, determinamos o custo total, usando os valores ótimos obtidos:

$$\begin{aligned}
C_{\text{minimo}} &= C_1 + C_2 \Leftrightarrow \\
C_{\text{minimo}} &= 0,3(0,7097) + 0,01(0,7097)^2 + 0,2(0,1903) + 0,3(0,1903)^2 \Leftrightarrow \quad (2.25) \\
C_{\text{minimo}} &= 0,2669(\text{€}/h)
\end{aligned}$$

Para a alinea b), como $P_{G1} = 0,5p.u.$, então:

$$\begin{aligned}
P_{G1} + P_{G2} &= 0,9 \Leftrightarrow 0,5 + P_{G2} = 0,9 \Leftrightarrow \\
P_{G2} &= 0,9 - 0,5 \Leftrightarrow P_{G2} = 0,4 p.u. \quad (2.26)
\end{aligned}$$

O custo total vai ser:

$$\begin{aligned}
C_T &= C_1 + C_2 \Leftrightarrow \\
C_T &= 0,3(0,7097) + 0,01(0,7097)^2 + 0,2(0,1903) + 0,3(0,1903)^2 \Leftrightarrow \quad (2.27) \\
C_T &= 0,2805(\text{€}/h)
\end{aligned}$$

Capítulo 3

APP em MATLAB

Com o objetivo de facilitar a análise e comparação dos métodos de resolução mencionados anteriormente (Secção 2.2), tanto através de funções de otimização convencionais, GA Toolbox (Secção 2.2.1), como através do desenvolvimento de algoritmos genéticos (Secções 2.2.2 e 2.2.3), criou-se uma aplicação interativa utilizando *App Designer* do MATLAB, tornando o processo de validação e comparação dos resultados mais simples e interativo.

Esta APP permite ao utilizador resolver os Ex 1 e 2, dos exercícios propostos pelo professor, de forma intuitiva, sendo possível seleccionar os parâmetros que é permitido variar e visualizar os resultados numéricos e gráficos. Apesar deste relatório se focar no Ex o 2, mantivemos o Ex 1, pois este nos permitiu explorar e testar as funcionalidades do *App Designer* durante as fases iniciais do desenvolvimento e também contribui para que a APP fique mais completa, uma vez que este exercício já tinha sido previamente desenvolvido se enquadra naturalmente na interface.

3.1 Menu Principal

O ecrã inicial da aplicação, **Menu Principal**, contém os botões necessários para aceder às funcionalidades principais da interface. Na Fig 3.1 podemos visualizar a interface inicial, onde o utilizador pode aceder aos exercícios que pretende resolver.




Figura 3.1: Fig que representa o Menu Inicial da APP

Os elementos presentes neste menu são:

- **Botão "Exercício 1"** - reencaminha-nos para a página dedicada à resolução do Ex 1, onde se estuda a otimização da função seno no intervalo $[0, 2\pi]$, permitindo determinando os seus pontos máximo e mínimo;
- **Botão "Exercício 2"** - reencaminha-nos para a página dedicada à resolução do Ex 2, onde estudamos o despacho económico de dois geradores sem perdas, determinando a distribuição ideal de potência que minimize os custos, conforme falado no Capítulo 2;
- **Botão "MENU PRINCIPAL"** - cria uma nova janela do **Menu Principal**, permitindo ao utilizador manter duas janelas ativas em simultâneo, facilitando a comparação lado a lado de métodos e configurações distintas;
- **Botão "Sair"** - permite encerrar a aplicação de forma direta e controlada, sem necessidade de utilizar os controlos padrão da janela.

Este menu serve assim como ponto de navegação central da APP, centrada na simplicidade de uso.

3.2 Ex 1

A janela dedicada ao Ex 1 apresenta uma interface simples, não muito explorada, pois este exercício não é aprofundado neste relatório, permitindo apenas determinar os valor máximo e mínimo da função Seno de forma interativa.



Figura 3.2: Fig que representa a APP do Ex 1 em MATLAB APP.

A estrutura da página inclui:

- **Dropdown de Seleção** - permite escolher se se pretende determinar o **Mínimo** ou o **Máximo** da função seno no intervalo $[0, 2\pi]$;
- **Botão "Toolbox"** - executa o método da MATLAB Optimization Toolbox, apresentando os gráficos da evolução do algoritmo e uma mensagem com o ângulo e o valor do ponto **Mínimo** ou **Máximo**, dependendo do escolhido no **Dropdown de Seleção**;
- **Botão "Gráfico"** - apresenta a curva do seno com a indicação visual do ponto selecionado (Mínimo ou Máximo);
- **Botão "MENU PRINCIPAL"** - retorna ao Menu Principal (Secção 3.1);
- **Botão "Sair"** - encerra a APP diretamente.

Esta página permite assim uma utilização rápida e intuitiva do Exercício 1, permitindo assim a resolução do mesmo.

3.3 Ex 2

Esta janela permite ao utilizador resolver o problema do despacho económico sem perdas, Ex 2, apresentando uma interface interativa e simples, permitindo variar os parâmetros do Algoritmo Genético e comparar diferentes métodos de resolução.

Nesta página, Fig 3.3, apresenta-se tudo que é necessário para a execução e análise dos resultados obtidos tanto pela *GA Toolbox* do MATLAB como pelo algoritmo genético desenvolvido.

Optimização-Despacho da Rede GA

EX2: Admitindo que a função custo de produção de cada um dos geradores são dadas pelas Equações (1) e (2):

$$C1(PG1) = 0,3 \cdot PG1 + 0,01 \cdot P^2G1;$$

$$C2(PG2) = 0,2 \cdot PG2 + 0,3 \cdot P^2G2;$$

Recorrendo à Toolbox de Otimização do MATLAB, será realizado, o despacho económico sem perdas da rede e comparação com os resultados obtidos.

Escolha da potência máxima do G1:

Defina parâmetros do GA:

Seleção --> Roleta	<i>PMax - Potencia Maxima</i>	0.9
Toolbox	<i>Npop - Número de População</i>	50
GA	<i>Nger - Número de Gerações</i>	100
Sair	<i>Pc - Probabilidade de Crossover</i>	0.8
Comparação	<i>Pm - Probabilidade de Mutação</i>	0.1

Figura 3.3: Fig que representa a APP do Ex 2 em MATLAB APP

Os elementos presentes são:

- **Dropdown de Seleção** - permite optar entre o método de Seleção **Roleta** e **Torneio**, já comentados nas Secções 2.2.2 e 2.2.3;
- **Definição de parâmetros variáveis** - o utilizador pode ajustar o limite máximo de potência do Gerador 1 (P_{max}), e parâmetros relativamente ao algoritmo genético desenvolvido, como o tamanho da população (N_{pop}), número de gerações (N_{ger}) e probabilidade de crossover (P_c) e mutação (P_m);
- **Botão "Toolbox"** - executa o problema utilizando a *GA Toolbox*, apresentando a solução obtida, os gráficos de convergência e a Curva do Custo Total com o ponto ótimo destacado;
- **Botão "Algoritmo Genético"** - executa o algoritmo desenvolvido de acordo com o método de seleção escolhido no **Dropdown**, apresentando gráficos de desempenho, como a Evolução do Custo Mínimo, a Curva do Custo Total (igual ao retratado na Toolbox) e a Distribuição da População Final;
- **Botão "Comparação"** - apresenta os resultados mais recentes obtidos pela Toolbox e pelo algoritmo desenvolvido, para uma análise rápida da eficácia de cada abordagem;

- **Botão "MENU PRINCIPAL"** - retorna ao Menu Principal (Secção 3.1);
- **Botão "Sair"** - encerra a APP diretamente.

Através desta interface, o utilizador pode controlar totalmente a otimização e observar a convergência em função dos parâmetros escolhidos, podendo assim comparar as diferentes estratégias em diversos casos.

3.3.1 Seleção do Método de Escolha

O primeiro elemento e um dos mais importantes na interface do Ex 2 é o **Dropdown de Seleção** responsável pela escolha do método de seleção do Algoritmo Genético. Podendo optar entre:

- **Seleção por Roleta** - método em que a probabilidade de seleção é proporcional à função *fitness* do indivíduo, já discutido na Secção 2.2.2;
- **Seleção por Torneio** - método em que pequenos grupos de indivíduos confrontam-se, sendo que o de menor custo ganha sempre, já analisado na Secção 2.2.3.

Após alterar esta opção, ao selecionar o **Botão "Algoritmo Genético"** a APP executa o método correspondente, podendo assim comparar os resultados tanto numéricos como gráficos entre métodos de seleção, apenas mudando a opção selecionada no Dropdown. Para além disso, de forma a evitar comparações incorretas entre os algoritmos desenvolvidos e a Toolbox, sempre que a opção da Seleção é alterada a APP limpa os resultados previamente obtidos.

Esta funcionalidade torna a análise muito mais intuitiva, permitindo ao utilizador observar como cada estratégia pode influenciar tanto a velocidade como a qualidade da solução final.

3.3.2 Definição dos Parâmetros Variáveis

De forma a permitir a variação de parâmetros proposta no exercício e a personalização do comportamento do Algoritmo Genético, a interface apresenta cinco campos numéricos onde é possível serem ajustados os seguintes parâmetros:

Parâmetro	Descrição
$P_{\max}$	Valor máximo permitido para as variáveis de decisão
N_{pop}	Número de indivíduos gerados por população
N_{ger}	Número total de gerações do algoritmo
P_c	Probabilidade de cruzamento
P_m	Probabilidade de mutação

Estes parâmetros permitem ao utilizador ter liberdade de testar diferentes intensidades de pressão evolutiva.

Validações Implementadas

De forma a preservar a veracidade dos resultados e evitar falhas de execução, a APP valida automaticamente o seguinte:

- $P_{\max}$ tem de ser maior que $P_{\min}$, 0.1, e menor que P_D , 0.9.
- P_c e P_m devem pertencer ao intervalo $[0, 1]$;
- N_{pop} , N_{ger} e $P_{\max}$ devem ser valores positivos estritamente maiores que zero;
- Todos os parâmetros devem estar preenchidos antes da simulação.

Caso alguma destas condições não seja satisfeita, a APP não autoriza a execução do algoritmo e apresenta uma mensagem de alerta ao utilizador, mencionando qual o erro ocorrido, como por exemplo:




Figura 3.4: Exemplo de alerta exibido quando $P_{\max}$ é inválido

Estas validações permitem ao utilizador não cometer erros ao utilizar a APP, garantindo que os resultados obtidos serão sempre viáveis.

3.3.3 Execução com a Toolbox do MATLAB

O Botão "Toolbox" permite resolver o problema do despacho económico através a GA Toolbox (Secção 2.2.1). Esta funcionalidade pode ser utilizada como referência de comparação para os resultados obtidos com o Algoritmo Genético desenvolvido para este trabalho, tanto para a Seleção por Roleta como para a Seleção por Torneio.

Durante a execução, são apresentados gráficos que nos permitem visualizar a evolução do algoritmo ao longo das gerações:

- `@gaplotbestf` — evolução do melhor valor do custo encontrado;
- `@gaplotbestindiv` — trajetória do melhor indivíduo por geração;
- `@gaplotexpectation` — expectativa de reprodução dos indivíduos;
- `@gaplotstopping` — verificação dos critérios de paragem.

Adicionalmente, foi criado um gráfico que representa a **curva do custo total em função** P_{G1} , permitindo identificar visualmente o ponto ótimo obtido pela Toolbox sobre a curva teórica do problema.

A Fig 3.5 apresenta um exemplo dos resultados gráficos, permitindo analisar a convergência do método.




Figura 3.5: Visualização da execução do AG através da GA Toolbox

Através destes gráficos, é possível verificar que:

- existe uma redução consistente do custo ao longo das gerações, refletindo a eficácia do método;
- a dispersão dos indivíduos diminui progressivamente, evidenciando a convergência para um ponto ótimo;
- o ponto ótimo determinado coincide com a região de menor custo da curva teórica calculada.

Para além dos resultados gráficos, a APP também apresenta uma mensagem resumindo os resultados numéricos obtidos:




Figura 3.6: Mensagem apresentada na APP com os resultados numéricos da Toolbox obtidos

Esta mensagem mostra ser algo mais visível para o utilizador, facilitando a leitura e comparação dos resultados. Torna assim a análise mais imediata e menos dependente da interpretação gráfica.

3.3.4 Execução do Algoritmo Genético Implementado

O Botão "Algoritmo Genético" executa o problema através dos algoritmos desenvolvidos por nós para este trabalho, sendo o método selecionado pelo Dropdown

(Secção 3.3.1). O funcionamento do código é detalhado na Secção 2.2.2 para a seleção por roleta e na Secção 2.2.3 para a seleção por torneio.

Durante o processo evolutivo, são atualizadas e armazenadas métricas essenciais, tanto para o decorrer do código como para a análise posteriormente:

- o custo mínimo por geração, permitindo acompanhar a convergência;
- os valores ótimos de P_{G1} , de forma a analisar a distribuição populacional.

No final da execução, são gerados três gráficos que permitem analisar o desempenho do algoritmo:




Figura 3.7: Resultados obtidos com o GA desenvolvido: (a) Evolução do custo mínimo, (b) Curva do Custo Total, com ponto ótimo assinalado, (c) Distribuição da população Final, P_{G1} .

A análise destes gráficos será falada brevemente mais à frente (Secção 3.3.7), podendo assim comparar ambos os métodos de seleção e a Toolbox.

Para além dos gráficos, também é mostrada uma mensagem resumindo os resultados obtidos na execução, de forma simples e direta, como na Toolbox:




Figura 3.8: Mensagem apresentada na APP com os resultados numéricos do Algoritmo Genético obtidos

3.3.5 Comparação dos Resultados

A APP tem um **Botão de Comparação**, que a função é apresentar uma mensagem com os últimos valores obtidos pelo Algoritmo Genético desenvolvido (seja por roleta ou torneio) e pela Toolbox do MATLAB. A mensagem que aparece é apresentada na Fig 3.9.





Figura 3.9: Mensagem apresentada pelo botão de Comparação na APP

Esta mensagem facilita na análise dos resultados, sendo algo direto e simples de forma a ser de fácil comparação.

A análise dos resultados mostra que os valores obtidos pelo Algoritmo Genético desenvolvido, quer por roleta ou torneio, são muito idênticos, senão iguais, aos fornecidos pela Toolbox. Indicando que ambos os métodos implementados fornecem soluções fidedignas, praticamente ótimas em relação à referência da Toolbox.

Quando se compara a eficiência dos métodos de seleção entre si, os valores numéricos são praticamente idênticos, como dito anteriormente idênticos aos valores da Toolbox, mas a análise da distribuição da população e da evolução do custo mínimo mostra diferenças importantes. A Fig 3.10 apresenta os gráficos obtidos da evolução do custo ao longo das gerações e a Fig 3.11 os gráficos que destacam a distribuição da população para cada método:



(a) Seleção por Roleta

(b) Seleção por Torneio

Figura 3.10: Comparação da evolução do custo mínimo entre os métodos de seleção




Figura 3.11: Comparação da distribuição da população entre os métodos de seleção

- **Seleção por Roleta:** a população mantém maior diversidade ao longo das gerações, não se concentrando exclusivamente na solução ótima. Desta forma existe uma maior exploração do espaço de busca, mas torna a convergência ligeiramente mais lenta.
- **Seleção por Torneio:** a população converge rapidamente para a solução ótima, havendo uma grande concentração dos indivíduos próximo do ponto ótimo. Também podemos observar que o decrescimento do custo ao longo das gerações é muito mais acentuado, demonstrando que este método apresenta uma pressão seletiva muito maior.

Esta comparação mostra que, apesar dos resultados numéricos finais serem muito idênticos, o comportamento de cada método é muito diferente, podendo influenciar a escolha do algoritmo em função do objetivo, maior exploração ou convergência mais rápida.

3.3.6 Tratamento de Erros e Robustez da Aplicação

Para garantir que a aplicação funciona de consistente, foram implementadas diversas validações. Algumas destas validações já foram mencionadas na Secção 3.3.2, mas são sumarizadas e justificadas a seguir:

- $P_{\max}$ Verificação de que $P_{\max} > P_{\min}$ e $P_{\max} \leq P_D$, evitando entradas fisicamente impossíveis que poderiam levar a resultados incorretos ou erros de execução;
- N_{pop} e N_{ger} : Devem de ser inteiros positivos, garantindo que o Algoritmo Genético possui população e número de gerações válidos, evitando erros de execução;
- P_c e P_m : Verificação se são positivos e menores que 1. Pois estes parâmetros representam probabilidades dos operadores de crossover e mutação;

- **Dropdown de Seleção:** Ao alterar o método no dropdown, o último resultado do Algoritmo Genético é automaticamente apagado, prevenindo comparações incorretas;
- **Atualização de parâmetros:** Ao modificar qualquer parâmetro ($P_{\max}$, N_{pop} , N_{ger} , P_c , P_m) é apagado automaticamente os últimos resultados do Algoritmo Genético e da Toolbox, garantindo que não existe comparação entre execuções com diferentes parâmetros;
- **Botão de Comparação:** Caso não tenha sido executado previamente ambos os métodos (Algoritmo Genético desenvolvido e Toolbox) ou os resultados tenham sido apagados devido a mudança de parâmetros ou de método, um alerta impede a comparação, evitando a exibição de valores inexistentes ou incorretos para a comparação.

As mensagens de alerta (*uialert*) avisam o utilizador de forma simples e direta de algo que tenha feito de errado. Por exemplo:

```

1 if ~isprop(app,'PG1_opt') || isempty(app.PG1_opt) || ...
2   ~isprop(app,'PG1_tool') || isempty(app.PG1_tool)
3     uialert(app.UIFigure, 'Por favor, execute primeiro os GAs
        Roleta e Toolbox.', 'Erro');
4     return;
5 end

```




Figura 3.12: Exemplo de alerta exibido quando não é possível fazer a comparação

Estas verificações e alertas tornam a APP mais fiável, prevenindo erros de execução e orientando o utilizador.

3.3.7 Resultados Obtidos

Acrónimos	P_{G1}	P_{G2}	Custo mínimo
Multiplicadores de Lagrange[6]	0,7097	0,1903	0,2668
Toolbox	0,7097	0,1903	0,2669
Seleção por Torneio	0,7098	0,1902	0,2669
Seleção por Roleta	0,7098	0,1902	0,2669

Capítulo 4

Conclusão

Este trabalho teve como objetivo desenvolver uma APP para resolver os exercícios propostos pelo professor Filipe Azevedo, recorrendo à Toolbox do MATLAB e projetar um Algoritmo genético escolhido por nós. A Toolbox e os multiplicadores de Lagrange dão as soluções ótimas para comparar com as soluções obtidas pelo nosso Algoritmo Genético, composto pelo método de seleção por torneio e pelo método de seleção por roleta.

A seleção por roleta prioriza a diversidade genética, não se concentra na solução ótima, o que torna a convergência mais lenta. A seleção por torneio é mais rápida a convergir para a solução ótima, ou seja, aumenta a pressão seletiva, mas eleva o risco de perda da diversidade genética se for excessivamente seletivo. O GA tem a opção de alterar os valores (N_{pop} , N_{ger} , P_c e P_m) sendo fundamental para analisar a velocidade e a qualidade da solução final.

Para concluir, os resultados obtidos na Toolbox e no nosso GA, observamos que as soluções ótimas são idênticas, tendo diferenças esperadas no comportamento de cada método de seleção. O sucesso do nosso GA afirma-se como um método de otimização fiável, mesmo em problemas com restrições.

Referências

- [1] JunqueiraDevEduardo, “Github - junqueiradeveduardo repositório.” <https://github.com/JunqueiraDevEduardo/MEECAlgoritmosGeneticos>. [Citado nas páginas 1 e 4]
- [2] Wikipedia contributors, “Cleve molerWikipedia, the free encyclopedia.” https://en.wikipedia.org/w/index.php?title=Cleve_Moler&oldid=1319905784, 2025. [Online; accessed 29-November-2025]. [Citado na página 2]
- [3] C. da Wikipédia, “John henry holland.” <https://pt.wikipedia.org/wiki/JohnHenryHolland>, Feb. 2022. [Citado na página 2]
- [4] C. da Wikipédia, “Algoritmo genetico.” <https://pt.wikipedia.org/wiki/Algoritmogenetico>, May 2025. [Citado na página 2]
- [5] F. Azevedo, “Moodle enunciado exercícios.” <https://moodle.isep.ipp.pt/pluginfile.php/53999/modresource/content/0/Exercicios.pdf>. [Citado nas páginas 4, 2, 3 e 5]
- [6] C. da Wikipédia, “Multiplicadores de lagrange.” <https://pt.wikipedia.org/wiki/MultiplicadoresdeLagrange>, Mar. 2025. [Citado nas páginas 11 e 25]