
Colónia de Formigas

Eduardo Junqueira nº 1251561, 1251561@isep.ipp.pt;
João Azevedo nº 1251566, 1251566@isep.ipp.pt;
Rodrigo Martins nº 1250398, 1250398@isep.ipp.pt;
Repositório GitHub: [1].
Supervisionado por Filipe Azevedo, fta@isep.ipp.pt.

Mestrado em Engenharia Electrotécnica e de Computadores
Área de Especialização em Automação e Sistemas



DEPARTAMENTO DE ENGENHARIA ELETROTÉCNICA
Instituto Superior de Engenharia do Porto

Novembro, 2025

Índice

Lista de Figuras	3
1 Introdução	2
1.1 Sistemas Naturais como Fonte de Inspiração	2
1.2 Da Biologia ao Algoritmo	2
1.3 Estrutura do Relatório	3
2 Estado da Arte	4
2.1 Inspiração Biológica- Comportamento Formigas	4
2.1.1 Comportamento coletivo e inteligência de enxame	4
2.1.2 Comunicação química e mecanismos de feedback	4
2.1.3 A experiência de Goss et al. (1989)	5
2.1.4 Variações experimentais e papel da memória	6
2.1.5 Da biologia à inspiração computacional	7
3 Desenvolvimento	8
3.1 Princípios da Otimização da Colônia de Formigas (ACO)	8
3.2 Modelação computacional do comportamento das formigas	8
3.3 ACO - Explicação de Etapas	9
3.3.1 Diagramas Explicativos	10
3.3.2 Pseudocódigo Representativo	11
3.4 TSP - Problema do Caixeiro Viajante	12
3.4.1 AS - Sistemas de Formigas	13
3.4.2 ACS - Sistema de Colônias de Formigas	16
4 Aplicação em Otimização	17
4.1 Explicação - Caso de estudo	17
4.2 Resultados:	17
5 Conclusão	19
Referências	20

Lista de Figuras

2.1	Resultados obtidos no esquema representativo do processo ,em cada arco, de <i>forrageamento</i> , salientando a concentração de feromonas depositadas [5].	5
2.2	Resultados obtidos em Labirintos usados por Goss et al. durante a experiência, sendo b uma variação mais complexa [2]	6
2.3	Resultados da experiência de Goss et al. , [2]	7
3.1	Grafo [7]	9
3.2	Diagrama de sobrevivência de uma formiga [10].	10
3.3	"Flowchart": descreve as etapas do processo do ciclo de alimentação das formigas, autoria própria feito no draw.io [10].	11
3.4	Escolha do caminho [10].	13
3.5	Escolha do melhor caminho TSP exemplo já implementado![13].	14
3.6	Possíveis movimentos da formiga $P(x)$, figura retirada das aulas teóricas aqui citada! [14].	14
4.1	Possíveis movimentos da formiga $P(x)$, figura retirada das aulas teóricas aqui citada! [14].	18

Resumo

Colônia de formigas no contexto de Algoritmos Genéticos é o algoritmo de estudo neste relatório. Este algoritmo tem como base os conceitos biológicos das formigas desde a sobrevivência em busca do alimento, reprodução da sua população e comunicação química por substância de feromonas.

O problema do Caixeiro Viajante - TSP, através deste algoritmo visa demonstrar a metodologia da melhor solução. Para este problema será explorado a otimização por colônias de formigas - ACO, no que diz respeito ao sistema de formigas - AS e ao sistema de colônia de formigas -ACS.

As aplicações em otimização neste algoritmo, são expostas como casos de uso aplicáveis para obter uma solução ótima.

Capítulo 1

Introdução

Muitos problemas de engenharia, logística e ciência da computação envolvem a necessidade de encontrar soluções ótimas num vasto espaço de possibilidades, frequentemente com restrições complexas. Entre estes desafios destaca-se o grupo dos problemas de otimização combinatória, como o Problema do Caixeiro Viajante (TSP), em que a procura por uma solução exata se torna impraticável devido ao crescimento exponencial do número de combinações. Por este motivo, métodos inspirados na natureza têm recebido crescente atenção, uma vez que permitem obter soluções de elevada qualidade com menor custo computacional.

1.1 Sistemas Naturais como Fonte de Inspiração

Entre os diversos sistemas biológicos estudados, o comportamento coletivo das colónias de formigas revelou-se particularmente relevante. Apesar das suas capacidades cognitivas individuais serem limitadas, estes insetos demonstram a capacidade de desempenhar tarefas complexas através da cooperação indireta, como encontrar rotas eficientes entre o ninho e fontes de alimento. Estudos experimentais, como o conduzido por Goss et al. [2], mostraram que este comportamento emerge da interação local entre os indivíduos e do uso de feromonas como mediadores ambientais.

1.2 Da Biologia ao Algoritmo

Este mecanismo natural serviu de inspiração para o algoritmo *Ant Colony Optimization* (ACO), introduzido por Dorigo na década de 1990 [3]. O ACO traduz matematicamente os princípios biológicos de reforço e evaporação das trilhas de feromonas, permitindo resolver problemas complexos de otimização com base em cooperação indireta entre agentes artificiais. Desde então, o método tem sido aplicado com sucesso em diversos domínios, destacando-se na resolução de problemas de trajetos mínimos, roteamento e planeamento de redes.

1.3 Estrutura do Relatório

O objetivo deste trabalho consiste no estudo do tema apresentado no título deste relatório: **Colônia de Formigas**. Com base neste estudo, será elaborado um relatório que aborda os principais aspectos do método da Colônia de Formigas, incluindo sua inspiração biológica, o funcionamento do algoritmo e suas aplicações em otimização.

Além disso, será apresentado um caso prático de otimização, onde o algoritmo será aplicado para demonstrar seu desempenho em um problema concreto. Desta forma, o relatório pretende fornecer uma visão completa, desde os fundamentos teóricos até a aplicação prática do método.

A sua estrutura é organizada da seguinte forma:

- Na Secção 2 descreve-se o comportamento natural das formigas e os resultados experimentais observados na literatura;
- Na Secção 3 é apresentada a formulação matemática do algoritmo ACO e os seus principais mecanismos de funcionamento;
- Na Secção 4 discutem-se aplicações práticas do ACO, com destaque para o TSP, apresentando um caso prático;
- Na Secção 5 são apresentadas as conclusões finais.

Capítulo 2

Estado da Arte

Dado o seguimento da introdução do Capítulo 1, será agora neste capítulo declarado o estado de arte do tema em estudo.

2.1 Inspiração Biológica- Comportamento Formigas

A biologia é o conceito base no estudo de algoritmos genéticos, mais propriamente no algoritmo genético da Colônia de formigas.

Assim, toda a genética e vida das formigas terá de ser estudada e entendida previamente antes do desenvolvimento deste relatório 3.

2.1.1 Comportamento coletivo e inteligência de enxame

As formigas são insetos sociais que fascinam biólogos e cientistas de computação devido à sua organização coletiva. Apesar de serem insetos cuja as suas capacidades cognitivas individuais são limitadas, em colônias, estas realizam tarefas de elevada complexidade, como defesa de território, construção de ninhos, mas especialmente, a procura eficiente de alimento, um processo chamado *forrageamento*. Este comportamento distribuído e cooperativo surge da interação de indivíduos simples que seguem regras locais, sem qualquer supervisão central. Essa forma de coordenação descentralizada é um exemplo clássico de *inteligência de enxame* (*Swarm Intelligence*). [4]

2.1.2 Comunicação química e mecanismos de feedback

Durante o processo de *forrageamento*, as formigas saem do ninho, inicialmente, deslocando-se de forma quase aleatória, em busca de alimento. Quando uma formiga encontra uma fonte de alimento, ela retorna ao ninho à medida que deixa no solo um rasto de uma substância química chamada *feromona*. Este atua como um mensageiro químico, que funciona como pista de comunicação indireta para as outras formigas da colônia, que vão tender a seguir rastos com maior concentração de feromonas. Gerando assim um sistema de *feedback positivo*: quanto maior o

número de formigas que percorrem uma determinada rota, maior vai ser a concentração de feromonas, levando assim a uma maior probabilidade de outras formigas também escolherem esse caminho. A figura em baixo descrita 2.1, demonstra o mencionado:




Figura 2.1: Resultados obtidos no esquema representativo do processo ,em cada arco, de *forrageamento*, salientando a concentração de feromonas depositadas [5].

Por outro lado, as feromonas também geram um sistema de *feedback negativo*, pois este evapora naturalmente com o tempo, impedindo que o sistema fique com soluções menos eficientes. Fortalecendo os caminhos mais curtos e vantajosos, à medida que as rotas mais longas e menos eficientes vão desaparecendo, resultando em um processo dinâmico de auto-organização. A combinação entre o reforço positivo e o esquecimento gradual permite com que a colônia esteja sempre a adaptar-se com o ambiente envolvente.

2.1.3 A experiência de Goss et al. (1989)

De forma a conseguir entender melhor este comportamento coletivo das formigas, Goss, Aron, Deneubourg e Pasteels em 1989, organizaram um dos estudos mais importantes nesta área. O principal objetivo deste experimento era compreender como as formigas escolhem o caminho entre o ninho e uma fonte de alimento, apesar das inúmeras possibilidades, e de que forma a comunicação química tinha influência.

Os pesquisadores utilizaram formigas da espécie *Lasius niger*, pois estas são conhecidas pelo seu comportamento de forrageamento bem organizado. A experiência consistia em um trajeto, em que o ponto de partida era o ninho, e a meio do caminho existia uma ramificação, dividindo o trajeto em dois caminhos possíveis, um mais curto e outro mais longo, que conduziam à mesma fonte de alimento. A figura a baixo 2.2, explica perfeitamente o referido anteriormente:




Figura 2.2: Resultados obtidos em Labirintos usados por Goss et al. durante a experiência, sendo b uma variação mais complexa [2]

No início do teste, as formigas não tinham qualquer informação sobre qual caminho era mais eficiente, sendo então a primeira fase da experiência dominada pela exploração quase aleatória. As primeiras formigas exploravam os dois caminhos de forma praticamente equilibrada até encontrarem alimento e regressarem ao ninho, depositando feromonas ao longo do processo. Começando então a surgir o mecanismo de *feedback positivo*, mencionado anteriormente, sendo então o caminho mais curto reforçado com feromonas mais cedo, tornando-o mais atrativo para as formigas que vão sair em busca de alimento.

Com o passar do tempo, mais e mais formigas começaram a escolher o mais curto, reforçando ainda mais a trilha química desse ramo. Havendo assim cada vez mais concentração de feromonas no caminho mais eficiente, enquanto diminuía gradualmente no trajeto mais longo devido à evaporação natural das feromonas (*feedback negativo*), diminuindo assim a frequência de passagem de formigas. O resultado deste comportamento foi descrito pelos autores como um “atalho auto-organizado” (*self-organized shortcut*), pois as formigas “descobriam” a rota mais vantajosa, sem que nenhuma delas tivesse conhecimento dos trajetos. Sendo então uma interação entre as formigas e o local e os sistemas de *feedback positivo* e *negativo* das feromonas. [2]

2.1.4 Variações experimentais e papel da memória

Depois os autores também realizaram variações do experimento, alterando o ângulo dos ramos, a diferença de comprimento entre os dois caminhos ou adicionando mais ramos como na Fig. 2.2. Observaram que quando a diferença entre os caminhos era pequena, a colônia demorava mais tempo a convergir para o caminho mais eficiente, enquanto se a diferença fosse maior, seria mais rápida essa conversão. Mostrando mais uma vez que a convergência para o caminho mais eficiente dependia da intensidade relativa das feromonas.

Na Figura 2.3 observa-se a distribuição de formigas entre o caminho curto e o longo ao longo da experiência, em função do número de trajetos realizados e da razão entre o comprimento dos dois ramos. Em (d), um dos ramos é bloqueado a meio da experiência, forçando as formigas a reorganizar a rota; em (h), um novo caminho mais curto é introduzido após diversas passagens

terem sido feitas pelo ramo original. Estes resultados demonstram a adaptação dinâmica da colônia ao ambiente através da deposição e evaporação de feromonas [2].




Figura 2.3: Resultados da experiência de Goss et al., [2]

Outro aspeto que foi observado pelos investigadores, foi a hipótese de as formigas poderem usar alguma forma de memória espacial (entre a esquerda e a direita) ao escolher entre duas ramificações equivalentes. Para isso, colocaram alimento numa das ramificações, e as formigas que encontraram o alimento foram marcadas; após isso, trocou-se os ramos por uns novos não marcados com feromonas e verificou-se que as formigas marcadas escolheram as duas ramificações de forma aproximadamente aleatória. Interpretando assim que a memória direcional das formigas tem um papel muito limitado e que a orientação depende sobretudo das feromonas deixadas durante o trajeto.

2.1.5 Da biologia à inspiração computacional

Resumindo, as observações de Goss e colegas demonstraram que a organização coletiva das formigas resulta da interação simples entre indivíduos e do uso de agentes químicos partilhados no ambiente. A ausência de uma memória direcional significativa e as feromonas como principal meio de comunicação, demonstram um sistema de coordenação indireta, onde o ambiente representa um mediador da informação. Este fenómeno, conhecido como *stigmergia*, permite que o grupo alcance soluções eficientes sem qualquer controlo centralizado ou comunicação direta entre indivíduos. Esta capacidade de resolver problemas complexos a partir de regras locais simples despertou o interesse de investigadores em várias áreas, levando à criação de modelos computacionais inspirados nesse comportamento natural, como o *Ant Colony Optimization (ACO)*, que traduz matematicamente estes princípios biológicos para aplicações em otimização.

Capítulo 3

Desenvolvimento

3.1 Princípios da Otimização da Colônia de Formigas (ACO)

A otimização da Colônia de Formigas (Ant Colony Optimization) é uma heurística baseada em probabilidade, publicado por Marco Dorigo em 1992 [6], tendo em vista a resolver problemas computacionais que envolvem a procura do melhor caminho em grafos. Como já foi esclarecido no capítulo 2, o ACO traduz matematicamente os princípios biológicos da formiga, em regras de probabilidade e em mecanismos matemáticos aplicáveis a problemas de otimização.

3.2 Modelação computacional do comportamento das formigas

As formigas artificiais são agentes computacionais que constroem soluções de forma incremental e com diferenças das formigas. As formigas artificiais têm alguma memória, não são completamente cegas e vivem num ambiente onde o tempo é discreto [6]. Cada formiga vai construir uma solução passo a passo e vai ser guiada através da feromona e da heurística disponível no problema. Como trabalham em conjunto e de forma autónoma, o algoritmo consegue explorar diferentes caminhos ao mesmo tempo e chegar a soluções mais eficazes.

A feromona é um valor numérico associado às ligações de grafo pela formiga artificial. O valor numérico indica a qualidade das soluções, ou seja, os caminhos com a melhor solução são as que têm níveis feromona maior. A formiga artificial tende a escolher o caminho com os níveis de feromona mais altos, como ilustrado na figura 3.1, e, desta forma, a feromona orienta o comportamento das formigas ao longo das iterações e ajuda o algoritmo a chegar às soluções mais eficazes.




Figura 3.1: Grafo [7]

A Heurística é um valor calculado com base em características imediatas do problema e que ajuda na orientação da decisão da formiga artificial. No início do algoritmo não há feromona suficiente, ou seja, as formigas não podem escolher o caminho completamente ao acaso. Então, a heurística indica quais são as opções que parecem mais favoráveis naquele momento do problema. No Travelling Salesman Problem (TSP), a heurística mais utilizada é o inverso da distância das cidades [8]. Neste caso, os trajetos com as cidades mais próximas vão ter uma heurística maior e as cidades com o trajeto mais longo vão ter uma heurística menor, o que favorece os trajetos mais curtos. Posto isto, a heurística complementa a feromona e contribui para escolhas mais detalhadas ao longo da construção da solução.

3.3 ACO - Explicação de Etapas

Após a explicação anterior, 3.1 e 3.2, agora será descrito as principais etapas que compõem o funcionamento do algoritmo de **Otimização de colônia de formigas (ACO — Ant Colony Optimization)**.

Este algoritmo tem sido amplamente aplicado em problemas combinatórios complexos tal como o **Travelling Salesman Problem TSP - Problema do Caixeiro Viajante** 3.4.

Este problema demonstra capacidade adaptativa e distribuída do ACO, no qual as soluções emergem da cooperação de múltiplos agentes simples, refletindo o comportamento coletivo das colônias naturais das formigas. Para isso é necessário primeiro entender o algoritmo heurístico ACO. O uso de heurísticas é de suma importância para resolver estes problemas combinatórios complexos.

A heurística não garante uma solução ótima, mas se tiver bem implementada e com parâmetros bem ajustados, garante uma boa solução a que atribuímos como **solução ótima**. Esta heurística é um algoritmo simples de fórmulas probabilísticas, que aumentam ou diminuem com base nos parâmetros dos problemas, que visam resolver problemas complexos. Assim, meta-heurística é uma ciência da computação complexa que procura precisamente uma heurística.

Neste caso a meta-heurística em estudo é a colônia de formigas-otimização [9]. Esta é uma heurística das várias meta-heurísticas na qual a unidade curricular tem, como caso de estudo, Algoritmos Genéticos.

3.3.1 Diagramas Explicativos

A figura em baixo 3.2, explica de uma forma mais visual que representa a topologia base presumida para o trabalho de procura de alimentos pelas formigas.




Figura 3.2: Diagrama de sobrevivência de uma formiga [10].

Cada ponto vermelho, corresponde às feromonas, (as feromonas das formigas são substâncias químicas que funcionam como um sistema de comunicação para orientação e alerta na colônia) de sentido ninho-fonte e fonte-ninho que são libertadas pelas formigas. Verifica-se que o caminho mais curto com menor distância é o que está com maior número de feromonas logo é o caminho da solução para a distância escolhida [11].

Assim, este caminho só será substituído por outro, caso exista evaporação das feromonas e o caminho não seja mais a solução para a fonte de alimento. O problema que será exposto aqui seria em reencontrar o caminho ótimo após uma alteração do percurso solução ou da fonte de alimento ou da inexistência de ambos.[11]

O flowchart em baixo na figura 3.3 explica em algoritmo, do tipo "flowchart", melhor a representação desta solução:




Figura 3.3: "Flowchart": descreve as etapas do processo do ciclo de alimentação das formigas, autoria própria feito no draw.io [10].

Este algoritmo é composto por um ciclo que alterna entre a fase inicial de exploração e a fase seguinte de atualização de feromona, até ser atingido um critério suficiente que seja a solução ótima ou uma solução escolhida que muitas vezes não é a solução ótima mas sim a escolhida por determinados fatores dependendo da utilização deste algoritmo[12].

3.3.2 Pseudocódigo Representativo

O funcionamento global do algoritmo pode ser sintetizado no seguinte pseudocódigo criado de acordo com o flowchart em cima 3.3:

/*

Pseudocódigo de Análise do problema ACO

-analisar distancia_fonte entre ninho e fonte;

```

-analisar a melhor solução;
*/
procedimento [melhor_local] = ColoniaFormigas(t_ij,t,populacao)
    // Definição das variáveis principais
    t_ij = 0          // nível de feromona acumulado para cada aresta/arco percorrido
    melhor_local      // armazena a melhor localização encontrada
    t = 0            // posição/estado inicial
    distancia         // distância percorrida para diferentes caminhos
    min_distancia = melhor_local    // menor distância encontrada melhor solução
    max_distancia = distancia       // maior distância: não é a melhor solução
    populacao = 50    // número de formigas definido inicialmente
    distancia_fonte // distancia ninho fonte

    // Inicializar variáveis para a exploração
    iniciar (distancia_fonte), (t), (t_ij);

    // Avaliar as diferentes posições até que todas tenham sido visitadas
    enquanto existirem posições a serem avaliadas (t != 0)
        // Verifica se a posição atual é a melhor possível
        se (distancia_fonte == min_distancia);

        então:
            (t_ij) != 0;          // aumenta trilha de feromona
            (melhor_local) = (min_distancia);
        se-não:
            (t_ij) = 0;          // trilha de feromona evaporado
            retorna (-1); // retorna a verificação!
        fim-se:
        // passar para a próxima posição caso seja aletardo distancia_fonte
        atualizar (t), (distancia_fonte);
    fim-enquanto:
    // Quando finalizar, retorna o melhor local encontrado
    retornar (melhor_local);
fim-procedimento

```

Este pseudocódigo pretende explicar de uma forma mais simples, ou seja, informal e simplificada de descrever os passos deste algoritmo, usando uma combinação de linguagem natural e elementos de programação para facilitar a leitura do mesmo.

3.4 TSP - Problema do Caixeiro Viajante

A heurística aqui no TSP, refere-se a regras que guiam as escolhas locais das formigas, por exemplo, a escolha preferencial de cidades próximas como próximos passos. O uso combinado da memória coletiva (caminhos de feromona) e da heurística local é importante no desempenho do ACO.

3.4.1 AS - Sistemas de Formigas


Ant System - AS, foi o primeiro algoritmo, foi criado em 1996 é uma das soluções para o problema do TSP - Problema do Caixeiro Viajante. Desenvolvido pelo autor mais citado neste relatório, Marco Dorigo [3].

"Marco Dorigo é um cientista da computação italiano, que trabalha com inteligência artificial, é diretor de pesquisa do Fundo Belga para Pesquisa Científica e codiretor do IRIDIA, o laboratório de inteligência artificial da Université Libre de Bruxelles"[13, 11].

As principais etapas do algoritmo AS são as seguintes:

1. **Parâmetros iniciais e feromona:** Define-se: **I**:o número de formigas, a que se chama de numero de população referente aos parâmetros de controlo (α, β, ρ); **II**: número máximo de iterações, e **III**: os valores iniciais do rastro de feromona τ_{ij} . Normalmente, o feromônio é inicializado com um valor constante τ_0 , distribuído de forma uniforme sobre todos os possíveis percursos.

Um exemplo esquemático de todos os possíveis recursos iniciais seria o seguinte na figura em baixo 3.4:



Qual é o caminho mais curto?

Aqui existe um problema, porque cada caminho têm diferente tamanho, sentido e direção. Assim, fica muito difícil de saber qual é o melhor caminho a percorrer

Figura 3.4: Escolha do caminho [10].


2. **Construção de soluções pelas formigas:** No esquema em baixo explicativo é possível verificar soluções para os melhores caminhos a percorrer 3.5

Dados:

- $V = \{v_1, \dots, v_m\}$ conjunto de cidades (nós)
- $A = \{(r, s) \mid r, s \in V\}$ conjunto de arestas (caminhos entre cidades)
- c_{rs} = custo associado à aresta (r, s)

Propósito:

- O caixeiro deve visitar todas as cidades
- Passando uma só vez em cada cidade
- Com o menor custo possível



TSP simétrico

Figura 3.5: Escolha do melhor caminho TSP exemplo já implementado! [13].

Cada formiga é colocada num ponto inicial ou nó (por exemplo, uma cidade no problema do caixeiro-viajante). Neste caso de 1 a 6.

As formigas constroem soluções de forma incremental, selecionando os próximos passos de acordo com uma probabilidade que combina a informação de feromona e uma função heurística [11].

A probabilidade P_{ij}^k de uma formiga k mover-se do nó i para o nó j é definida por:

$$P_{ij}^k = \frac{(\tau_{ij})^\alpha (\eta_{ij})^\beta}{\sum_{l \in N_i^k} (\tau_{il})^\alpha (\eta_{il})^\beta} \quad (3.1)$$

onde a explicação é a seguinte:

- τ_{ij} representa a intensidade do feromônio na ligação (i, j) ;
- η_{ij} é a informação heurística (ex: inverso da distância) [8]

$$\eta_{ij} = \frac{1}{d_{ij}} \quad (3.2)$$

- α e β controlam a importância relativa destes dois fatores τ_{ij} e η_{ij} ;
- N_i^k é o conjunto de movimentos disponíveis para a formiga k a partir do nó i . No esquema em baixo explicativo é possível verificar soluções para os melhores caminhos a percorrer 3.6




Figura 3.6: Possíveis movimentos da formiga $P(x)$, figura retirada das aulas teóricas aqui citada! [14].

$P(A), P(B), P(C)$, representam o conjunto N_i^k , para onde o somatório do mesmo é realizado apenas sobre as possíveis soluções não repetindo os nós i já existentes pelas formigas k .

3. **Avaliação das soluções:** Após todas as formigas completarem as suas soluções, avalia-se a qualidade de cada uma através da função objetivo do problema (ex: distância total do percurso). Identifica-se a melhor solução encontrada (solução ótima) na iteração e, ou opcionalmente, a melhor solução global até o momento.

Após cada formiga construir uma solução (um ciclo completo, no caso do TSP), o custo total do percurso (função objetivo) para a formiga k é definido por:

$$L_k = \sum_{(i,j) \in S_k} d_{ij} \quad (3.3)$$

onde:

- S_k é o conjunto ordenado de arestas visitadas pela formiga k (percurso construído);
- d_{ij} é a distância/custo associado entre os nós (cidades) i e j [11, 14].

No fim de cada iteração:

- A **melhor solução da iteração** é determinada por:

$$L_{\text{best iter}} = \min_k L_k \quad (3.4)$$

- A **melhor solução global até o momento** pode ser atualizada por:

$$L_{\text{global best}} = \min(L_{\text{best anterior}}, L_{\text{best iter}}) \quad (3.5)$$

O caminho correspondente ao menor L é armazenado como a solução ótima até há última verificação. Todo este processo é essencial para o ciclo de atualização dos feromônios e procura dos melhores percursos.

4. **Atualização dos feromônios:** Os rastros de feromônio são atualizados com base nas soluções construídas. Parte da feromona existente evapora, e uma nova quantidade é depositada nas rotas pertencentes às melhores soluções [11], [8].

O processo é descrito pela fórmula:

$$\tau_{ij} \leftarrow (1 - \rho)\tau_{ij} + \sum_{k=1}^m \Delta\tau_{ij}^k \quad (3.6)$$

onde:

- ρ é a taxa de evaporação que está entre os valores: $]0,1[$;
- se a formiga k usou o arco (i,j) ; caso contrário, $\Delta\tau_{ij}^k = 0$;

$$\Delta\tau_{ij}^k = \frac{Q}{L_k} \quad (3.7)$$

- Q é uma constante que regula a quantidade de feromônio depositado;
- L_k é o custo (ou comprimento) da solução encontrada pela formiga k .

5. **Critério de paragem:** O algoritmo termina quando é atingido o número máximo de iterações, ou quando as feromonas convergem, isto é, quando a maioria das formigas passa a escolher a mesma rota (indicando estabilidade da solução).

3.4.2 ACS - Sistema de Colónias de Formigas

Ant Colony System - ACS foi uma evolução do Ant System em 1997 por Marco Dorigo [3]. Dorigo, motivou o desenvolvimento de uma nova meta-heurística de otimização baseada em colónias de formigas.

Dorigo e colaboradores verificaram que o Ant System - AS original, embora inovador, tendia a convergir de forma relativamente lenta e, em alguns casos, a soluções sub-ótimas devido a um controlo menos rigoroso da atualização de feromônio. Esta limitação motivou a definição de novas regras de decisão e de atualização de trilhos de feromônio, resultando no ACS como meta-heurística mais robusta e eficiente.

O ACS surge assim como uma evolução direta do AS, mantendo a ideia central de múltiplas formigas cooperativas mas adiciona estratégias mais complexas de exploração-exploração. Em particular, o algoritmo passa a utilizar regras de escolha de arestas e de atualização de feromônio desenhadas para intensificar a busca nas regiões mais promissoras do espaço de soluções, reduzindo simultaneamente o risco de estagnação prematura.

A atualização global de feromônio no ACS é aplicada apenas às arestas pertencentes ao melhor caminho conhecido (por exemplo, o melhor desde o início da execução), o que reforça fortemente esse conjunto de arestas. Nesta atualização, o nível de feromônio em cada aresta selecionada sofre evaporação e recebe depois um incremento inversamente proporcional ao comprimento do melhor caminho, concentrando o feromônio nas soluções mais curtas, como representado nas figuras anteriores 3.1 e 3.5.

.....

Capítulo 4

Aplicação em Otimização

Existe vários casos de estudo referente há utilização deste algoritmo em estudo. Ambos têm um objetivo que é encontrar a melhor solução possível, resolvendo o problema do caixeiro viajante - TSP.

O caso de estudo que será analisado é uma aplicação em python que consiste em resolver o problema com base neste algoritmo de estudo[15].

4.1 Explicação - Caso de estudo

4.2 Resultados:

Esta secção é referenciada e citada pelos diagramas que explicam o mencionado anteriormente do caso de estudo[15].

Após executar o caso de estudo que está inserido na base de dados do repositório é possível observar em baixo na figura 4.1:




Figura 4.1: Possíveis movimentos da formiga $P(x)$, figura retirada das aulas teóricas aqui citada! [14].

Capítulo 5

Conclusão

Referências

- [1] E. Junqueira, “Github - junqueiradeveduardo repositório.” <https://github.com/JunqueiraDevEduardo/MEECAgoritmosGeneticos>. [Citado na página 1]
- [2] S. Goss, S. Aron, J.-L. Deneubourg, and J. Pasteels, “Self-organized shortcuts in the argentine ant. naturwissenschaften 76: 579-581,” *Naturwissenschaften*, vol. 76, pp. 579–581, 12 1989. [Citado nas páginas 3, 2, 6 e 7]
- [3] C. da Wikipédia, “Marco dorigo criador do algoritmo genético.” <https://pt.wikipedia.org/wiki/MarcoDorigo>, Feb.2021. [Citado nas páginas 2, 13 e 16]
- [4] E. Bonabeau, M. Dorigo, and G. Theraulaz, “Swarm intelligence : From natural to artificial systems / e. bonabeau, m. dorigo, g. theraulaz.,” 01 2001. [Citado na página 4]
- [5] M. A. Awadallah, S. N. Makhadmeh, M. A. Al-Betar, L. M. Dalbah, A. Al-Redhaei, S. Kouka, and O. S. Enshassi, “Multi-objective ant colony optimization: Review,” *ARCHIVES OF COMPUTATIONAL METHODS IN ENGINEERING*, vol. 32, pp. 995–1037, MAR 2025. [Citado nas páginas 3 e 5]
- [6] M. Dorigo, V. Maniezzo, and A. Coloni, “The ant system: Optimization by a colony of cooperating agents,” *IEEE Transactions on Systems, Man, and Cybernetics, Part B*, vol. 26, no. 1, pp. 29–41, 1996. [Citado na página 8]
- [7] F. Breve, *Otimização por Colônia de Formigas (Ant Colony Optimization)*, 2025. Material didático disponível em <https://www.fabriciobreve.com/material/cin/CIN-11-ACO.pdf>. [Citado nas páginas 3 e 9]
- [8] F. De Economia, “Ant colony optimization: a literature survey.” <https://hdl.handle.net/10216/70687>, 2012. [Citado nas páginas 9, 14 e 15]
- [9] C. da Wikipédia, “Meta-heurística.” <https://pt.wikipedia.org/wiki/Meta-heur> [Citado na página 9]
- [10] E. Junqueira, “Diagramas draw.io colônia de formigas: flowcharts.” <https://app.diagrams.net/>. [Citado nas páginas 3, 10, 11 e 13]
- [11] F. Breve, “Ant colony optimization.” <https://www.fabriciobreve.com/material/cin/CIN-11-ACO.pdf>, 2024. Apostila, UNESP. [Citado nas páginas 10, 13, 14 e 15]
- [12] “Fork github.” <https://github.com/JunqueiraDevEduardo/col-nia-formigas-caixairo-viajante.git>. [Citado na página 11]
- [13] imeunicampbr, “Journal ant colony optimization.” <https://www.ime.unicamp.br/chico/mt852/formigas>, 2009. [Citado nas páginas 3, 13 e 14]
- [14] F. Azevedo, “Genetic_algorithms_course.pdf.” [Citado nas páginas 3, 14, 15 e 18]

- [15] “Fork github - caixeiro-viajante-exemplo-python.” https://github.com/JunqueiraDevEduardo/TSP_ACO_Exemplo_rico_colonia_formigas_otimizacao_caso_de_u_so. [Citado na página 17]